

Caso Práctico 1:

Motor de recomendación de películas

Carlos Galán · Máster IEP · Recommendation Systems

Objetivo y preparación de los datos

El objetivo de este caso práctico es construir y comparar tres sistemas de recomendación: uno basado en popularidad, otro basado en usuarios similares y otro basado en películas similares. Para ello utilizamos los ficheros `file.tsv` y `Movie_Id_Titles.csv`, que contienen las valoraciones de MovieLens y la relación entre los identificadores y los títulos de las películas.

En primer lugar cargamos ambos ficheros con pandas, eliminamos la fecha porque no interviene en ninguno de los métodos y unimos las tablas. El resultado contiene 100.003 valoraciones de 944 usuarios. Después construimos una matriz usuario-película de 944×1.664 . Aproximadamente el 93,65 % de sus celdas están vacías, algo lógico porque ningún usuario ha visto todo el catálogo. Hemos mantenido esos huecos como valores desconocidos: rellenarlos con cero habría sido equivalente a considerar que una película no vista tiene la peor nota.

Métodos implementados

El primer recomendador ordena las películas por número de valoraciones. Es el método más sencillo y coloca *Star Wars* (1977) en primera posición. Su principal ventaja es que funciona desde la primera visita, cuando todavía no conocemos al usuario. El problema es bastante evidente: todo el mundo recibe la misma lista y los títulos menos conocidos apenas tienen posibilidades de aparecer.

Para el filtrado colaborativo basado en usuarios hemos comparado Pearson y coseno. De manera sencilla, Pearson se fija en si dos usuarios siguen un patrón parecido aunque uno puntúe normalmente más alto que otro. El coseno comprueba si sus valoraciones apuntan en una dirección similar y suele funcionar bien cuando hay muchos huecos en la matriz. En ambos casos exigimos al menos 20 películas en común para que la comparación tenga una base suficiente.

Para generar las recomendaciones finales hemos elegido coseno. No tiene por qué ser el mejor criterio, pero encaja bien con un dataset con tantos valores nulos. Después seleccionamos los 20 vecinos más cercanos y calculamos las recomendaciones mediante una media ponderada por su similitud.

El tercer enfoque compara películas. Usamos también coseno, pero esta vez transponemos la matriz y exigimos al menos 50 usuarios en común. Partimos de los títulos que el usuario ha valorado con 4 o 5 y, para cada película candidata, conservamos la relación más fuerte encontrada. La tabla y la gráfica se ordenan por esa similitud, mientras que la columna “porque” muestra la película del historial que la ha provocado. He preferido mantener este método sencillo porque permite entender directamente de dónde sale cada recomendación.

Comparación de los resultados

Los tres métodos sirven para situaciones diferentes. Popularidad es útil cuando todavía no tenemos ninguna valoración, pero devuelve prácticamente la misma lista a todos los usuarios. El filtrado usuario-usuario ya tiene en cuenta el historial, aunque necesita suficientes coincidencias para encontrar vecinos fiables. El filtrado ítem-ítem también personaliza y, además, permite explicar cada resultado a partir de una película que el usuario ya conoce. Su principal limitación es que los títulos con pocas valoraciones tienen más dificultades para aparecer.

CineMatch como ampliación visual

Como parte adicional he desarrollado CineMatch, una web que permite crear un perfil, valorar películas y ver cómo cambian las recomendaciones. La aplicación parte de las mismas tres ideas del notebook —popularidad, usuarios similares e ítems similares—, pero las adapta a un escenario interactivo.

En la web un perfil puede empezar con solo cinco valoraciones, por lo que no tendría sentido exigir las 20 coincidencias del notebook. La versión online usa también similitud coseno, pero con umbrales menos restrictivos. En el filtro ítem-ítem no conserva solo la mejor relación: utiliza todas las valoraciones del perfil y calcula para cada candidata una media ponderada por sus similitudes. Así obtiene una valoración estimada entre 1 y 5. Después combina este ranking con usuarios similares y popularidad mediante pesos dinámicos. He añadido también perfiles locales y metadatos de TMDb (para tener la descripción de las pelis, el cartel, género, etc), además de una pestaña con información sobre el motor de recomendación que estamos usando.

En esta pestaña se explican de forma visual los tres métodos utilizados, el peso que tiene cada uno según la cantidad de valoraciones del perfil y cómo aporta cada método al resultado final. También se muestra qué ocurre cada vez que puntuamos una película y por qué algunos títulos quedan fuera del ranking.

Conclusión

Con este caso podemos ver el paso desde una recomendación general hasta una personalizada. Si tuviera que escoger un único método colaborativo para este dataset, me quedaría con el basado en ítems porque es estable y podemos justificar fácilmente de dónde sale cada resultado. Pero en una plataforma real, se usa la popularidad para los perfiles nuevos y se combinan después varias señales, que es precisamente lo que he intentado representar con CineMatch.